

Week 5: 传统 AI Baseline 与安全筛查指标


Traditional ML baselines for three-phase microgrid N-1 screening

ECE Course: Physics-informed AI for Microgrid Security Prediction

本周学习目标

- ① 将 Week 4 的三相 N-1 label 数据转化为监督学习数据集。
- ② 建立 pre-contingency feature set, 并证明没有 target leakage。
- ③ 训练 rule-based、logistic regression、random forest、gradient boosting 和 MLP baseline。
- ④ 用 recall、FNR、AUPRC、PF calls saved 和 top-k recall 评价安全筛查器。
- ⑤ 在 validation set 上选择高召回阈值, 在 test set 上只评估一次。
- ⑥ 比较 random split、scenario-group CV 和 contingency-group CV。

八周项目中的位置



Week 5 的作用

把三相 N-1 数据变成可复现实验基线，为 Week 6/7 的物理约束模型提供比较对象。

Week 4 输出

$$(x_t, c_k) \mapsto (y_{t,k}, s_{t,k})$$

- operating scenario
- N-1 contingency
- safe / unsafe label
- severity score

Week 5 输出

$$\hat{p}_{t,k} = f_{\theta}(x_t, c_k)$$

- violation probability
- high-recall threshold
- calls saved vs missed violations
- top-k ranking

Binary classification

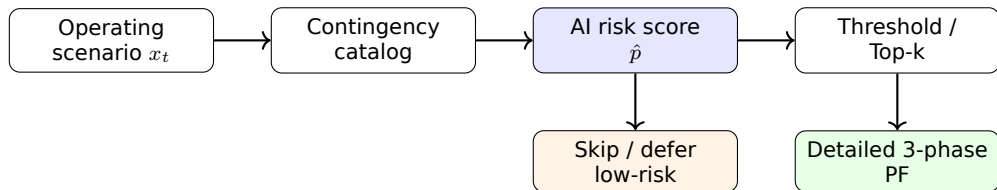
$$\hat{y}_{t,k}(\tau) = \mathbb{I}\{f_{\theta}(x_t, c_k) \geq \tau\}$$

- $\hat{y} = 1$: 送入详细三相 N-1 潮流验证。
- $\hat{y} = 0$: 暂时跳过或延后该 contingency。
- false negative: unsafe contingency 被错误跳过。

安全重点

在安全筛查中, false negative 比 false positive 更危险。

AI 筛查器在流程中的位置



核心定位

AI 不替代潮流求解器，而是作为 pre-screening module。

为什么不能只看 accuracy

普通分类任务

- accuracy 常作为第一指标。
- 两类错误代价可能接近。

安全筛查任务

- false negative: 漏掉危险故障。
- false positive: 多运行一次潮流。
- 两者代价不对称。

结论

Week 5 重点看 recall、FNR、missed violations 和 PF calls saved。

混淆矩阵的工程解释

	$\hat{y} = 0$ skip	$\hat{y} = 1$ run PF
$y = 0$ safe	TN	FP
$y = 1$ unsafe	FN	TP

- TP : 危险样本被送入详细潮流。
- FP : 安全样本被送入详细潮流，浪费计算。
- TN : 安全样本被跳过，节省计算。
- FN : 危险样本被跳过，最危险。

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{FNR} = \frac{FN}{TP + FN} = 1 - \text{Recall}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{PF calls saved} = TN + FN$$

$$\text{Saved ratio} = \frac{TN + FN}{N}$$

$$\text{Workload} = \frac{TP + FP}{N}$$

解释

Saved ratio 必须和 missed violations 一起报告。

High-recall threshold selection

$$\tau^* = \arg \max_{\tau} \text{SavedRatio}_{val}(\tau), \quad \text{s.t. } \text{Recall}_{val}(\tau) \geq R_{target}$$

- 默认 $R_{target} = 0.95$ 。
- threshold 只能在 validation set 上选择。
- test set 只用于最后一次性能报告。

实验纪律

如果在 test set 上调 threshold，就会造成评价泄漏。

允许

- load scale, phase factors
- PV scale, BESS setpoint
- base-case min voltage
- base-case max loading
- base-case VUF
- contingency type / metadata

禁止

- post-contingency voltage
- post-contingency loading
- post-contingency VUF
- unserved load
- convergence flag
- violation flags
- label and severity

No-leakage proof in Notebook

```
forbidden_tokens = [  
    "converged", "min_vm", "max_vm", "max_vuf",  
    "max_line_loading", "unserved", "violation",  
    "severity", "pf_status",  
]  
leaky_features = [c for c in feature_cols  
                  if is_forbidden_feature(c)]  
assert not leaky_features
```

证明目标

模型输入只能使用真实部署时刻能拿到的信息。

Dataset schema proof

- ① row id 唯一。
- ② 每个 $(scenario, contingency)$ 只出现一次。
- ③ target 是二元变量，且 safe / unsafe 都存在。
- ④ severity 非负。
- ⑤ violation flags 的 OR 与 final label 一致。

本次数据集

样本数 $N = 77$; unsafe = 47; safe = 30; pre-contingency features = 32。

- ① **AllUnsafe**: 召回高但不省计算。
- ② **EngineeringRule**: 用 base-case stress 和 contingency type 构造规则分数。
- ③ **LogisticRegression**: 线性、可解释。
- ④ **RandomForest**: 非线性 tabular baseline。
- ⑤ **GradientBoosting**: 强树模型 baseline。
- ⑥ **MLP**: Week 6 neural model 起点。

Numeric

- median imputation
- standard scaling

Categorical

- most-frequent imputation
- one-hot encoding
- handle unknown categories

Pipeline 设计

所有模型使用相同 feature set 和 split, 确保 baseline comparison 公平。

Notebook training loop

```
for name, model in models.items():  
    model.fit(X_train, y_train)  
    val_score = model.predict_proba(X_val)[:, 1]  
    tau = choose_high_recall_threshold(  
        y_val, val_score, target_recall=0.95)  
    test_score = model.predict_proba(X_test)[:, 1]  
    report_metrics(y_test, test_score, tau)
```


Random holdout split

Split	Samples	Unsafe	Violation rate
Train	39	24	0.615
Validation	18	11	0.611
Test	20	12	0.600

局限

Random split 适合 debug，但还需要 group CV。


Holdout results

Model	τ	Recall	Prec.	FNR	Saved	Missed	AUPRC
AllUnsafe	0.000	1.000	0.600	0.000	0.000	0	0.600
EngineeringRule	0.650	1.000	0.857	0.000	0.300	0	0.910
LogisticRegression	0.735	0.833	1.000	0.167	0.500	2	1.000
RandomForest	0.677	0.833	0.909	0.167	0.450	2	0.956
GradientBoosting	0.301	1.000	1.000	0.000	0.400	0	1.000
MLP	0.000	1.000	0.600	0.000	0.000	0	0.533


本次选择

Selected model: **GradientBoosting**, $\tau = 0.301$.


Precision-recall curves



Recall vs threshold



Saved PF calls vs missed violations



Random split 问题

- 相同 scenario family 可能进测试集。
- 相同 contingency family 可能进测试集。
- 泛化能力可能被高估。

Group CV 目标

- scenario-group CV: unseen operating scenarios。
- contingency-group CV: unseen outages。
- 更接近论文泛化评估。

$$\mathcal{S}_{train} \cap \mathcal{S}_{test} = \emptyset$$

- 测模型是否能泛化到没有见过的 operating condition。
- Notebook 中每个 fold 都断言 train/test scenario 不重叠。

$$\mathcal{C}_{train} \cap \mathcal{C}_{test} = \emptyset$$

- 测模型是否能泛化到没有见过的 outage。
- 小数据集上通常更困难。

Cross-validation summary

CV protocol	Model	Recall	FNR	Saved	AUPRC
contingency_group	EngineeringRule	1.000	0.000	0.310	0.971
contingency_group	LogisticRegression	0.254	0.746	0.786	0.909
contingency_group	RandomForest	0.400	0.600	0.690	0.861
scenario_group	EngineeringRule	1.000	0.000	0.323	0.912
scenario_group	LogisticRegression	0.928	0.072	0.439	0.990
scenario_group	RandomForest	0.899	0.101	0.475	0.990

解读

Random split 是 debug 结果；group CV 才能支持泛化声明。

$$\text{Top-}k(x_t) = \text{argsort}_k f_\theta(x_t, c)$$

$$\text{ViolationRecall@}k = \frac{|\text{Top-}k \cap \mathcal{V}_t|}{|\mathcal{V}_t|}$$

$$\text{SevereHit@}k = \mathbb{I}\{\arg \max_c s_{t,c} \in \text{Top-}k\}$$


Top-k results

k	Mean recall@k	Min recall@k	Severe hit@k	PF fraction
1	0.156	0.091	1.000	0.091
2	0.312	0.182	1.000	0.182
3	0.468	0.273	1.000	0.273
5	0.779	0.455	1.000	0.455
8	0.961	0.727	1.000	0.727
10	0.987	0.909	1.000	0.909


解释

Top-k 模式适合先验证最危险的若干 contingencies。

Top-k violation recall curve



Random forest feature importance



Manual metric proof

$$TP = \sum_i \mathbb{I}\{y_i = 1, \hat{y}_i = 1\}, \quad FP = \sum_i \mathbb{I}\{y_i = 0, \hat{y}_i = 1\}$$

$$TN = \sum_i \mathbb{I}\{y_i = 0, \hat{y}_i = 0\}, \quad FN = \sum_i \mathbb{I}\{y_i = 1, \hat{y}_i = 0\}$$

Notebook 会将手算结果与 sklearn confusion matrix 逐项对比。

Notebook validation summary: **12/12 checks passed.**

- schema proof
- target has two classes
- no-feature-leakage proof
- split disjoint proof
- threshold chosen on validation proof
- manual confusion matrix proof
- group CV proof
- top-k and reproducibility proof
- output figures exist

```
week5_baseline_dataset.csv  
week5_holdout_results.csv  
week5_cv_summary.csv  
week5_validation_summary.csv  
week5_screening_tradeoff.csv  
week5_topk_violation_recall.csv  
week5_precision_recall_curves.png  
week5_recall_threshold_curves.png  
week5_saved_calls_vs_missed_violations.png  
week5_feature_importance.png
```


- ① 读取 Week 4 AI-ready dataset。
- ② 合并 Week 3 base-case features。
- ③ 运行 schema proof 和 leakage guard。
- ④ 训练 rule-based 和 ML baselines。
- ⑤ 用 validation set 选择 threshold。
- ⑥ 在 test set 上报告 safety metrics。
- ⑦ 运行 scenario / contingency group CV。
- ⑧ 导出结果表和图。

- ① 加入 engineered feature, 例如 distance to PCC 或 downstream load。
- ② 比较加入该 feature 前后的 recall、FNR 和 saved ratio。
- ③ 将目标 recall 从 0.95 改成 0.90, 观察节省计算量变化。
- ④ 解释为什么 AllUnsafe baseline 重要。

$$\mathcal{L}_{data} = \text{BCE}(y, \hat{p})$$

$$\mathcal{L} = \mathcal{L}_{data} + \lambda_{lim}\mathcal{L}_{limit} + \lambda_{rank}\mathcal{L}_{rank} + \lambda_{cal}\mathcal{L}_{calibration}$$

- Week 5 给出数据、指标和 baseline。
- Week 6 在此基础上加入物理约束和多任务损失。

安全预测模型的价值不是“分类准确”，而是在可控漏报风险下减少昂贵的三相 N-1 潮流计算。

high recall + low missed violations + useful PF-call reduction