

Week 5: 传统 AI Baseline 与安全筛查指标


Traditional ML baselines for three-phase microgrid N-1 screening

ECE Course: Physics-informed AI for Microgrid Security Prediction

本周学习目标

- ① 将 Week 4 的三相 N-1 label 数据转化为监督学习数据集。
- ② 建立 pre-contingency feature set, 并证明没有 target leakage。
- ③ 训练 rule-based、logistic regression、random forest、gradient boosting 和 MLP baseline。
- ④ 用 recall、FNR、AUPRC、PF calls saved 和 top-k recall 评价安全筛查器。
- ⑤ 在 validation set 上选择高召回阈值, 在 test set 上只评估一次。
- ⑥ 比较 random split、scenario-group CV 和 contingency-group CV。

八周项目中的位置



Week 5 的作用

把三相 N-1 数据变成可复现实验基线，为 Week 6/7 的物理约束模型提供比较对象。

Week 4 输出

$$(x_t, c_k) \mapsto (y_{t,k}, s_{t,k})$$

- operating scenario
- N-1 contingency
- safe / unsafe label
- severity score

Week 5 输出

$$\hat{p}_{t,k} = f_{\theta}(x_t, c_k)$$

- violation probability
- high-recall threshold
- calls saved vs missed violations
- top-k ranking

Binary classification


$$\hat{y}_{t,k}(\tau) = \mathbb{I}\{f_{\theta}(x_t, c_k) \geq \tau\}$$

- $\hat{y} = 1$: 送入详细三相 N-1 潮流验证。
- $\hat{y} = 0$: 暂时跳过或延后该 contingency。
- false negative: unsafe contingency 被错误跳过。

安全重点

在安全筛查中, false negative 比 false positive 更危险。

AI 筛查器在流程中的位置



核心定位

AI 不替代潮流求解器，而是作为 pre-screening module。

为什么不能只看 accuracy

普通分类任务

- accuracy 常作为第一指标。
- 两类错误代价可能接近。

安全筛查任务

- false negative: 漏掉危险故障。
- false positive: 多运行一次潮流。
- 两者代价不对称。

结论

Week 5 重点看 recall、FNR、missed violations 和 PF calls saved。

混淆矩阵的工程解释

	$\hat{y} = 0$ skip	$\hat{y} = 1$ run PF
$y = 0$ safe	TN	FP
$y = 1$ unsafe	FN	TP

- TP : 危险样本被送入详细潮流。
- FP : 安全样本被送入详细潮流，浪费计算。
- TN : 安全样本被跳过，节省计算。
- FN : 危险样本被跳过，最危险。

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{FNR} = \frac{FN}{TP + FN} = 1 - \text{Recall}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{PF calls saved} = TN + FN$$

$$\text{Saved ratio} = \frac{TN + FN}{N}$$

$$\text{Workload} = \frac{TP + FP}{N}$$

解释

Saved ratio 必须和 missed violations 一起报告。

High-recall threshold selection

$$\tau^* = \arg \max_{\tau} \text{SavedRatio}_{val}(\tau), \quad \text{s.t. } \text{Recall}_{val}(\tau) \geq R_{target}$$

- 默认 $R_{target} = 0.95$ 。
- threshold 只能在 validation set 上选择。
- test set 只用于最后一次性能报告。

实验纪律

如果在 test set 上调 threshold, 就会造成评价泄漏。

特征选择：允许 vs 禁止

允许

- load scale, phase factors
- PV scale, BESS setpoint
- base-case min voltage
- base-case max loading
- base-case VUF
- contingency type / metadata

禁止

- post-contingency voltage
- post-contingency loading
- post-contingency VUF
- unserved load
- convergence flag
- violation flags
- label and severity

No-leakage proof in Notebook

```
forbidden_tokens = [  
    "converged", "min_vm", "max_vm", "max_vuf",  
    "max_line_loading", "unserved", "violation",  
    "severity", "pf_status",  
]  
leaky_features = [c for c in feature_cols  
                  if is_forbidden_feature(c)]  
assert not leaky_features
```

证明目标

模型输入只能使用真实部署时刻能拿到的信息。

Dataset schema proof

- ① row id 唯一。
- ② 每个 $(scenario, contingency)$ 只出现一次。
- ③ target 是二元变量，且 safe / unsafe 都存在。
- ④ severity 非负。
- ⑤ violation flags 的 OR 与 final label 一致。

本次数据集

样本数 $N = 77$; unsafe = 47; safe = 30; pre-contingency features = 32。

- ① **AllUnsafe**: 召回高但不省计算。
- ② **EngineeringRule**: 用 base-case stress 和 contingency type 构造规则分数。
- ③ **LogisticRegression**: 线性、可解释。
- ④ **RandomForest**: 非线性 tabular baseline。
- ⑤ **GradientBoosting**: 强树模型 baseline。
- ⑥ **MLP**: Week 6 neural model 起点。

Numeric

- median imputation
- standard scaling

Categorical

- most-frequent imputation
- one-hot encoding
- handle unknown categories

Pipeline 设计

所有模型使用相同 feature set 和 split, 确保 baseline comparison 公平。

Notebook training loop

```
for name, model in models.items():  
    model.fit(X_train, y_train)  
    val_score = model.predict_proba(X_val)[:, 1]  
    tau = choose_high_recall_threshold(  
        y_val, val_score, target_recall=0.95)  
    test_score = model.predict_proba(X_test)[:, 1]  
    report_metrics(y_test, test_score, tau)
```


Random holdout split

Split	Samples	Unsafe	Violation rate
Train	39	24	0.615
Validation	18	11	0.611
Test	20	12	0.600

局限

Random split 适合 debug, 但还需要 group CV。


Holdout results

Model	τ	Recall	Prec.	FNR	Saved	Missed	AUPRC
AllUnsafe	0.000	1.000	0.600	0.000	0.000	0	0.600
EngineeringRule	0.650	1.000	0.857	0.000	0.300	0	0.910
LogisticRegression	0.735	0.833	1.000	0.167	0.500	2	1.000
RandomForest	0.677	0.833	0.909	0.167	0.450	2	0.956
GradientBoosting	0.301	1.000	1.000	0.000	0.400	0	1.000
MLP	0.000	1.000	0.600	0.000	0.000	0	0.533


本次选择

Selected model: **GradientBoosting**, $\tau = 0.301$ 。

Precision-recall curves




Recall vs threshold



解释

阈值越高，模型越少判为 unsafe，计算量可能下降，但 recall 也可能下降。

Saved PF calls vs missed violations



解释

如果节省计算的代价是漏掉 unsafe contingency，则部署不可接受。

Random split 问题

- 相同 scenario family 可能进测试集。
- 相同 contingency family 可能进测试集。
- 泛化能力可能被高估。

Group CV 目标

- scenario-group CV: unseen operating scenarios。
- contingency-group CV: unseen outages。
- 更接近论文泛化评估。

$$\mathcal{S}_{train} \cap \mathcal{S}_{test} = \emptyset$$

- 测模型是否能泛化到没有见过的 operating condition。
- Notebook 中每个 fold 都断言 train/test scenario 不重叠。

$$\mathcal{C}_{train} \cap \mathcal{C}_{test} = \emptyset$$

- 测模型是否能泛化到没有见过的 outage。
- 小数据集上通常更困难。

Cross-validation summary

CV protocol	Model	Recall	FNR	Saved	AUPRC
contingency_group	EngineeringRule	1.000	0.000	0.310	0.971
contingency_group	LogisticRegression	0.254	0.746	0.786	0.909
contingency_group	RandomForest	0.400	0.600	0.690	0.861
scenario_group	EngineeringRule	1.000	0.000	0.323	0.912
scenario_group	LogisticRegression	0.928	0.072	0.439	0.990
scenario_group	RandomForest	0.899	0.101	0.475	0.990

解读

Random split 是 debug 结果；group CV 才能支持泛化声明。

$$\text{Top-}k(x_t) = \text{argsort}_k f_\theta(x_t, c)$$

$$\text{ViolationRecall@}k = \frac{|\text{Top-}k \cap \mathcal{V}_t|}{|\mathcal{V}_t|}$$

$$\text{SevereHit@}k = \mathbb{I}\{\arg \max_c s_{t,c} \in \text{Top-}k\}$$


Top-k results

k	Mean recall@k	Min recall@k	Severe hit@k	PF fraction
1	0.156	0.091	1.000	0.091
2	0.312	0.182	1.000	0.182
3	0.468	0.273	1.000	0.273
5	0.779	0.455	1.000	0.455
8	0.961	0.727	1.000	0.727
10	0.987	0.909	1.000	0.909


解释

Top-k 模式适合先验证最危险的若干 contingencies。

Top-k violation recall curve



Random forest feature importance



提醒

Feature importance 不是因果解释，但能帮助检查模型是否依赖合理 stress indicators。

$$TP = \sum_i \mathbb{I}\{y_i = 1, \hat{y}_i = 1\}, \quad FP = \sum_i \mathbb{I}\{y_i = 0, \hat{y}_i = 1\}$$

$$TN = \sum_i \mathbb{I}\{y_i = 0, \hat{y}_i = 0\}, \quad FN = \sum_i \mathbb{I}\{y_i = 1, \hat{y}_i = 0\}$$

Notebook 会将手算结果与 sklearn confusion matrix 逐项对比。

Notebook validation summary: **12/12 checks passed**。

- schema proof
- target has two classes
- no-feature-leakage proof
- split disjoint proof
- threshold chosen on validation proof
- manual confusion matrix proof
- group CV proof
- top-k and reproducibility proof
- output figures exist

Notebook 输出文件

```
week5_baseline_dataset.csv  
week5_holdout_results.csv  
week5_cv_summary.csv  
week5_validation_summary.csv  
week5_screening_tradeoff.csv  
week5_topk_violation_recall.csv  
week5_precision_recall_curves.png  
week5_recall_threshold_curves.png  
week5_saved_calls_vs_missed_violations.png  
week5_feature_importance.png
```


- ① 读取 Week 4 AI-ready dataset。
- ② 合并 Week 3 base-case features。
- ③ 运行 schema proof 和 leakage guard。
- ④ 训练 rule-based 和 ML baselines。
- ⑤ 用 validation set 选择 threshold。
- ⑥ 在 test set 上报告 safety metrics。
- ⑦ 运行 scenario / contingency group CV。
- ⑧ 导出结果表和图。

- 1 加入 engineered feature, 例如 distance to PCC 或 downstream load。
- 2 比较加入该 feature 前后的 recall、FNR 和 saved ratio。
- 3 将目标 recall 从 0.95 改成 0.90, 观察节省计算量变化。
- 4 解释为什么 AllUnsafe baseline 重要。

$$\mathcal{L}_{data} = \text{BCE}(y, \hat{p})$$

$$\mathcal{L} = \mathcal{L}_{data} + \lambda_{lim}\mathcal{L}_{limit} + \lambda_{rank}\mathcal{L}_{rank} + \lambda_{cal}\mathcal{L}_{calibration}$$

- Week 5 给出数据、指标和 baseline。
- Week 6 在此基础上加入物理约束和多任务损失。

安全预测模型的价值不是“分类准确”，而是在可控漏报风险下减少昂贵的三相 N-1 潮流计算。

high recall + low missed violations + useful PF-call reduction