

Week 6: Physics-informed AI for 三相微电网 N-1 安全筛查


Limit-aware multi-task MLP with proof and cross-validation

ECE Course: Physics-informed AI for Microgrid Security Prediction

本周学习目标

- ① 从 Week 5 的二元分类 baseline 过渡到 multi-task PI-MLP。
- ② 把三相静态安全约束转化为 voltage/loading/VUF/service component margins。
- ③ 构造 severity head、component head、consistency loss 和 ranking loss。
- ④ 严格证明 no-leakage: post-contingency 结果只能作为目标，不能作为输入。
- ⑤ 使用 validation set 选择 high-recall threshold，在 test set 上最终评估。
- ⑥ 用 scenario-group CV 和 contingency-group CV 检查泛化能力。

八周项目中的位置



Week 6 的角色

把“会分类”的模型升级为“知道为什么 unsafe”的模型，为 Week 7 图模型和 Week 8 论文消融实验做准备。

Week 5 black-box classifier

$$\hat{p} = f_{\theta}(x_t, c_k)$$

- 输出 unsafe probability。
- 难解释 violation 来源。
- ranking 能力不一定稳定。

Week 6 PI-MLP

$$(\hat{p}, \hat{s}, \hat{\mathbf{m}}) = f_{\theta}(x_t, c_k)$$

- unsafe probability $\hat{p}$;
- severity $\hat{s}$;
- component margins $\hat{\mathbf{m}}$;
- consistency + ranking losses。

本周的 physics-informed 含义

不是

不是直接把完整三相潮流方程嵌入神经网络，也不是让 MLP 替代 pandapower 的三相潮流求解器。

而是

把 Week 4 标签中的物理结构显式加入学习目标：

- voltage limits;
- phase current / loading limits;
- voltage unbalance factor limits;
- service-loss / no-slack topology risk;
- severity and contingency ranking.

允许作为输入

- scenario settings;
- base-case voltage / VUF / loading;
- base-case PCC import;
- contingency type;
- element metadata.

禁止作为输入

- post-contingency voltage;
- post-contingency loading;
- post-contingency VUF;
- convergence flag;
- service loss amount;
- violation label / severity.

$$\mathcal{X}_{input} \cap \mathcal{Y}_{post} = \emptyset$$

从 Week 4 数据得到:

$$y \in \{0, 1\}, \quad s_{raw} \geq 0$$

以及 violation flags:

- voltage low / voltage high;
- loading violation;
- VUF violation;
- non-convergence;
- service loss / critical service loss。

Week 6 将这些转成 PI auxiliary targets:

$$\mathbf{m} = [m_{V,low}, m_{V,high}, m_I, m_U, m_S].$$

Component margin: 低电压

设低电压阈值为:

$$V^{min} = 0.95 \text{ p.u.}$$

低电压 margin:

$$m_{V,low} = \left[\frac{V^{min} - V_{min}^{obs}}{V^{min}} \right]_+$$

解释

当 $V_{min}^{obs} \geq V^{min}$ 时, margin 为 0; 当电压越限越严重时, margin 越大。

Component margin: 高电压

设高电压阈值为：

$$V^{max} = 1.05 \text{ p.u.}$$

高电压 margin：

$$m_{V,high} = \left[\frac{V_{max}^{obs} - V^{max}}{V^{max}} \right]_+$$

微电网场景

高 PV、低负荷和反向潮流场景下，高电压 violation 可能成为主导风险。

Component margin: 线路 loading

线路 loading 阈值:

$$L^{max} = 100\%$$

loading margin:

$$m_I = \left[\frac{L_{max}^{obs}}{100} - 1 \right]_+$$

- L_{max}^{obs} 是 N-1 后最大三相 line loading。
- 该目标把 thermal/current risk 显式告诉模型。

Component margin: VUF

VUF 阈值示例:

$$U^{max} = 2\%$$

VUF margin:

$$m_U = \left[\frac{U_{max}^{obs}}{U^{max}} - 1 \right]_+$$

三相故事线的核心

在不平衡微电网中，仅预测 voltage magnitude 不够；VUF 是相不平衡风险的重要标签。

对于 radial LV feeder, 某些 line outage 会导致 downstream load 失供。

$$m_S = \max(y_{service}, y_{critical\ service}, y_{no\ slack})$$

- 该目标来自拓扑可供电性逻辑。
- 它不依赖连续潮流结果。
- 对 PCC outage / no-slack case 尤其重要。

$$s_{PI} = \max(s_{raw}, m_{V,low}, m_{V,high}, m_I, m_U, m_S)$$

目标一致性 proof


$$s_{PI} \geq \max_k m_k$$

这保证 overall severity 不会比任何 component margin 更乐观。

为什么重要

如果 severity head 预测很低，但 component head 预测某项越限很大，模型解释会自相矛盾。

模型结构：shared encoder + multi-head



非负输出

severity 和 component margins 通过 softplus 输出，避免出现负风险。

$$\mathcal{L}_{cls} = -w_+ y \log \hat{p} - (1 - y) \log(1 - \hat{p})$$

- unsafe/safe 样本可能不平衡。
- class weight 只是训练技术，不等于安全保证。
- 最终安全性仍要靠 threshold、recall、FNR 和 missed violations 评估。

Severity regression loss

$$\mathcal{L}_{sev} = \text{SmoothL1}(\log(1 + \hat{s}), \log(1 + s_{PI}))$$

为什么用 $\log(1 + s)$

severity 可能跨不同量级；使用 log transform 可以降低极端样本对训练的支配。

Component margin loss

$$\mathcal{L}_{comp} = \sum_k \text{SmoothL1}(\log(1 + \hat{m}_k), \log(1 + m_k))$$

解释性

component head 让模型回答: unsafe 是因为 voltage、loading、VUF, 还是 service-loss?

Limit consistency loss

$$\mathcal{L}_{cons} = \left[\max_k \hat{m}_k - \hat{s} \right]_+^2$$

物理含义

overall predicted severity 至少应覆盖最严重 predicted component violation。

如果预测 severity 很大，unsafe probability 不应该很低。

$$\mathcal{L}_{prob-sev} = (\sigma(z) - \sigma(\alpha(\hat{s} - \epsilon)))^2$$

- z 是 classification logit。
- $\hat{s}$ 是 predicted severity。
- 该项鼓励 probability 和 severity 同向变化。

Pairwise ranking loss

对于一个 mini-batch 中两条样本，如果：

$$s_i > s_j$$

希望模型满足：

$$\hat{s}_i > \hat{s}_j$$

ranking loss：

$$\mathcal{L}_{rank} = [\delta - (\hat{s}_i - \hat{s}_j)]_+$$

用途


帮助模型把高风险 contingency 排到 top-k 列表前面。

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_s \mathcal{L}_{sev} + \lambda_c \mathcal{L}_{comp} + \lambda_{cons} \mathcal{L}_{cons} + \lambda_p \mathcal{L}_{prob-sev} + \lambda_r \mathcal{L}_{rank}$$

课程重点

每个 loss term 都对应一个工程假设或物理一致性要求；Week 6 不是寻找最优 λ ，而是训练学生建立 loss design 思维。

训练和阈值选择流程



$$\tau^* = \arg \max_{\tau} \text{SavedRatio}_{val}(\tau) \quad \text{s.t.} \quad \text{Recall}_{val}(\tau) \geq 0.95$$

Proof 1: no leakage

```
leakage_cols = [  
    'converged', 'min_vm_pu', 'max_vm_pu',  
    'max_vuf_percent', 'max_line_loading_percent',  
    'unserved_load_mw', 'violation_label',  
    'severity_score', ...]  
feature_cols = [c for c in df.columns  
                 if c not in identifier_cols + leakage_cols]  
assert not set(feature_cols).intersection(leakage_cols)
```

结果

当前数据集通过 no-leakage 检查，输入特征数为 33，one-hot 后维度为 45。

Proof 2: target consistency

Notebook 检查:

$$y = 0 \Rightarrow s_{raw} = 0$$

$$y = 1 \Rightarrow s_{raw} > 0$$

$$s_{PI} \geq \max_k m_k$$

当前执行

所有 target consistency checks 通过; validation suite 共 16 项全部通过。

Proof 3: finite loss and gradients

在一个 mini-batch 上检查:

- model output shape 是否正确;
- total loss 是否 finite;
- 每个可训练参数的 gradient 是否 finite;
- predicted probability 是否在 $[0, 1]$ 。

工程意义

复杂 multi-task loss 很容易因为 log、division、NaN target 导致训练失败，因此必须先做最小 batch proof。

Proof 4: manual confusion matrix

$$TP + FP + TN + FN = N_{test}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{FNR} = \frac{FN}{TP + FN}$$

PI-MLP test set 当前结果

$TP = 12, FP = 0, TN = 8, FN = 0$; Recall = 1.00; FNR = 0.00; PF calls saved fraction = 0.40。

Holdout results

Model	Recall	Precision	FNR	Saved	Missed
BaselineMLP	1.00	0.857	0.00	0.30	0
PI-MLP full	1.00	1.000	0.00	0.40	0

说明

当前数据集很小，holdout 结果只用于教学验证；论文版必须扩展 scenario 数量和多随机种子。


Loss ablation results

Model	Recall	Precision	Saved	AUPRC
BaselineMLP	1.00	0.857	0.30	1.00
PI-MLP no-rank	1.00	0.923	0.35	1.00
PI-MLP full	1.00	1.000	0.40	1.00

教学解读

本例中 full PI-MLP 在高召回下节省更多 PF 调用；小数据上不宜过度解读绝对数值。


Training curves



观察

validation loss 用于 early stopping; 但最终安全指标仍然是 recall、FNR 和 missed violations。


Precision-recall curves



为什么看 PR curve

安全筛查通常是类别不均衡问题，PR curve 比 accuracy 更关注 positive/unsafe 样本识别能力。


Saved PF calls vs missed violations



工程解释

任何 saved PF calls 都要和 missed violations 同时报告；不能只说加速。


True PI severity vs predicted severity



用途

检查 severity head 是否学到风险强弱，而不是只学二元标签。

Component target distribution



解释性入口

component target distribution 能帮助学生理解数据集中主要风险来自哪类约束。

Scenario-group 与 contingency-group CV

CV type	Folds	Mean recall	Mean FNR	Mean saved
Scenario-group	3	0.928	0.072	0.207
Contingency-group	3	0.760	0.240	0.413

关键结论

contingency-group CV 更难，说明仅靠 tabular metadata 泛化到未见过 contingency 仍有限；这是 Week 7 GNN 的动机。

Reproducibility proof

Notebook 重新用相同随机种子训练 PI-MLP，并检查 test probabilities:

$$\max_i |\hat{p}_i^{(run1)} - \hat{p}_i^{(run2)}| < 10^{-6}$$

当前结果

最大差异为 0.000×10^0 级别，fixed-seed reproducibility check 通过。

Validation suite

当前 notebook 共检查 16 项:

- schema and binary labels;
- label/severity consistency;
- PI severity dominates component margins;
- no-leakage feature set;
- disjoint train/validation/test split;
- finite preprocessing, finite loss, finite gradients;
- manual confusion matrix;
- threshold selected from validation;
- scenario/contingency group CV disjoint;
- fixed-seed reproducibility。

结果

16/16 passed。

主要 CSV

- training curves;
- holdout results;
- loss ablation summary;
- group CV results;
- screening tradeoff;
- test predictions;
- validation summary。

主要 figures

- training curves;
- precision-recall curves;
- saved calls vs missed violations;
- true vs predicted severity;
- component target distribution。

- 当前样本数只有 77，用于教学足够，但论文版必须生成更大 scenario pool。
- PI-MLP 仍是 tabular model，没有显式编码 feeder topology。
- contingency-group CV 暴露出对未见 contingency 的泛化压力。
- λ 权重尚未系统搜索。
- 尚未做 uncertainty calibration / conformal screening。

Week 6 PI-MLP

- tabular features;
- contingency metadata;
- PI loss design;
- high-recall screening。

Week 7 Phase-aware GNN

- bus/phase nodes;
- line/device edges;
- contingency mask;
- topology-aware generalization。

核心动机

把拓扑从 feature engineering 中解放出来，交给图模型显式学习。

- ① 把 VUF 阈值从 2 percent 改成 1.5 percent, 观察 component margin 分布。
- ② 关闭 prob_sev loss, 检查 probability 与 severity 是否仍然同向。
- ③ 关闭 ranking loss, 对比 top-k contingency ordering。
- ④ 把 target recall 从 0.95 改成 1.00, 观察 saved PF calls 如何变化。
- ⑤ 思考: 哪些内容应该保留到 Week 7 的 GNN loss 中?

- Notebook 使用 PyTorch 实现 multi-head MLP 和自定义 loss。
- 使用 scikit-learn 完成 preprocessing、AUPRC/AUROC 与 GroupKFold。
- 所有结果表和图表保存在 week6_outputs_complete/。
- clean notebook 适合课堂发放；executed notebook 适合教师检查和复现。