

## Week 6: Physics-informed AI for 三相微电网 N-1 安全筛查


Limit-aware multi-task MLP with proof and cross-validation

ECE Course: Physics-informed AI for Microgrid Security Prediction

## 本周学习目标

- ① 从 Week 5 的二元分类 baseline 过渡到 multi-task PI-MLP。
- ② 把三相静态安全约束转化为 voltage/loading/VUF/service component margins。
- ③ 构造 severity head、component head、consistency loss 和 ranking loss。
- ④ 严格证明 no-leakage: post-contingency 结果只能作为目标，不能作为输入。
- ⑤ 使用 validation set 选择 high-recall threshold，在 test set 上最终评估。
- ⑥ 用 scenario-group CV 和 contingency-group CV 检查泛化能力。

## 八周项目中的位置



### Week 6 的角色

把“会分类”的模型升级为“知道为什么 unsafe”的模型，为 Week 7 图模型和 Week 8 论文消融实验做准备。

## Week 5 black-box classifier

$$\hat{p} = f_{\theta}(x_t, c_k)$$

- 输出 unsafe probability。
- 难解释 violation 来源。
- ranking 能力不一定稳定。

## Week 6 PI-MLP

$$(\hat{p}, \hat{s}, \hat{\mathbf{m}}) = f_{\theta}(x_t, c_k)$$

- unsafe probability  $\hat{p}$ ;
- severity  $\hat{s}$ ;
- component margins  $\hat{\mathbf{m}}$ ;
- consistency + ranking losses。

## 本周的 physics-informed 含义

### 不是

不是直接把完整三相潮流方程嵌入神经网络，也不是让 MLP 替代 pandapower 的三相潮流求解器。

### 而是

把 Week 4 标签中的物理结构显式加入学习目标：

- voltage limits;
- phase current / loading limits;
- voltage unbalance factor limits;
- service-loss / no-slack topology risk;
- severity and contingency ranking。

## 允许作为输入

- scenario settings;
- base-case voltage / VUF / loading;
- base-case PCC import;
- contingency type;
- element metadata。

## 禁止作为输入

- post-contingency voltage;
- post-contingency loading;
- post-contingency VUF;
- convergence flag;
- service loss amount;
- violation label / severity。

$$\mathcal{X}_{input} \cap \mathcal{Y}_{post} = \emptyset$$

# Supervised target 设计

从 Week 4 数据得到:

$$y \in \{0, 1\}, \quad s_{raw} \geq 0$$

以及 violation flags:

- voltage low / voltage high;
- loading violation;
- VUF violation;
- non-convergence;
- service loss / critical service loss。

Week 6 将这些转成 PI auxiliary targets:

$$\mathbf{m} = [m_{V,low}, m_{V,high}, m_I, m_U, m_S].$$

## Component margin: 低电压

设低电压阈值为:

$$V^{min} = 0.95 \text{ p.u.}$$

低电压 margin:

$$m_{V,low} = \left[ \frac{V^{min} - V_{min}^{obs}}{V^{min}} \right]_+$$

### 解释

当  $V_{min}^{obs} \geq V^{min}$  时, margin 为 0; 当电压越限越严重时, margin 越大。



## Component margin: 高电压

设高电压阈值为:

$$V^{max} = 1.05 \text{ p.u.}$$

高电压 margin:

$$m_{V,high} = \left[ \frac{V_{max}^{obs} - V^{max}}{V^{max}} \right]_+$$

### 微电网场景

高 PV、低负荷和反向潮流场景下，高电压 violation 可能成为主导风险。

## Component margin: 线路 loading

线路 loading 阈值:

$$L^{max} = 100\%$$

loading margin:

$$m_I = \left[ \frac{L_{max}^{obs}}{100} - 1 \right]_+$$

- $L_{max}^{obs}$  是 N-1 后最大三相 line loading。
- 该目标把 thermal/current risk 显式告诉模型。

## Component margin: VUF

VUF 阈值示例:

$$U^{max} = 2\%$$

VUF margin:

$$m_U = \left[ \frac{U_{max}^{obs}}{U^{max}} - 1 \right]_+$$

### 三相故事线的核心

在不平衡微电网中，仅预测 voltage magnitude 不够；VUF 是相不平衡风险的重要标签。

对于 radial LV feeder, 某些 line outage 会导致 downstream load 失供。

$$m_S = \max(y_{service}, y_{critical\ service}, y_{no\ slack})$$

- 该目标来自拓扑可供电性逻辑。
- 它不依赖连续潮流结果。
- 对 PCC outage / no-slack case 尤其重要。

$$s_{PI} = \max(s_{raw}, m_{V,low}, m_{V,high}, m_I, m_U, m_S)$$

### 目标一致性 proof


$$s_{PI} \geq \max_k m_k$$

这保证 overall severity 不会比任何 component margin 更乐观。

### 为什么重要

如果 severity head 预测很低，但 component head 预测某项越限很大，模型解释会自相矛盾。

## 模型结构: shared encoder + multi-head



### 非负输出

severity 和 component margins 通过 softplus 输出，避免出现负风险。

$$\mathcal{L}_{cls} = -w_+ y \log \hat{p} - (1 - y) \log(1 - \hat{p})$$

- unsafe/safe 样本可能不平衡。
- class weight 只是训练技术，不等于安全保证。
- 最终安全性仍要靠 threshold、recall、FNR 和 missed violations 评估。

$$\mathcal{L}_{sev} = \text{SmoothL1}(\log(1 + \hat{s}), \log(1 + s_{PI}))$$

为什么用  $\log(1 + s)$

severity 可能跨不同量级；使用 log transform 可以降低极端样本对训练的支配。



$$\mathcal{L}_{comp} = \sum_k \text{SmoothL1}(\log(1 + \hat{m}_k), \log(1 + m_k))$$

### 解释性

component head 让模型回答: unsafe 是因为 voltage、loading、VUF, 还是 service-loss ?

$$\mathcal{L}_{cons} = \left[ \max_k \hat{m}_k - \hat{s} \right]_+^2$$

### 物理含义

overall predicted severity 至少应覆盖最严重 predicted component violation。

如果预测 severity 很大，unsafe probability 不应该很低。

$$\mathcal{L}_{prob-sev} = (\sigma(z) - \sigma(\alpha(\hat{s} - \epsilon)))^2$$

- $z$  是 classification logit。
- $\hat{s}$  是 predicted severity。
- 该项鼓励 probability 和 severity 同向变化。

## Pairwise ranking loss

对于一个 mini-batch 中两条样本，如果：

$$s_i > s_j$$

希望模型满足：

$$\hat{s}_i > \hat{s}_j$$

ranking loss：

$$\mathcal{L}_{rank} = [\delta - (\hat{s}_i - \hat{s}_j)]_+$$

### 用途

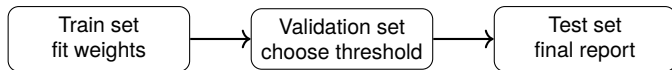
帮助模型把高风险 contingency 排到 top-k 列表前面。

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_s \mathcal{L}_{sev} + \lambda_c \mathcal{L}_{comp} + \lambda_{cons} \mathcal{L}_{cons} + \lambda_p \mathcal{L}_{prob-sev} + \lambda_r \mathcal{L}_{rank}$$

## 课程重点

每个 loss term 都对应一个工程假设或物理一致性要求；Week 6 不是寻找最优  $\lambda$ ，而是训练学生建立 loss design 思维。

## 训练和阈值选择流程



$$\tau^* = \arg \max_{\tau} \text{SavedRatio}_{val}(\tau) \quad \text{s.t.} \quad \text{Recall}_{val}(\tau) \geq 0.95$$

## Proof 1: no leakage

```
leakage_cols = [  
    'converged', 'min_vm_pu', 'max_vm_pu',  
    'max_vuf_percent', 'max_line_loading_percent',  
    'unserved_load_mw', 'violation_label',  
    'severity_score', ...]  
feature_cols = [c for c in df.columns  
                 if c not in identifier_cols + leakage_cols]  
assert not set(feature_cols).intersection(leakage_cols)
```

### 结果

当前数据集通过 no-leakage 检查，输入特征数为 33，one-hot 后维度为 45。

## Proof 2: target consistency

Notebook 检查:

$$y = 0 \Rightarrow s_{raw} = 0$$

$$y = 1 \Rightarrow s_{raw} > 0$$

$$s_{PI} \geq \max_k m_k$$

当前执行

所有 target consistency checks 通过; validation suite 共 16 项全部通过。



## Proof 3: finite loss and gradients

在一个 mini-batch 上检查：

- model output shape 是否正确；
- total loss 是否 finite；
- 每个可训练参数的 gradient 是否 finite；
- predicted probability 是否在  $[0, 1]$ 。

### 工程意义

复杂 multi-task loss 很容易因为 log、division、NaN target 导致训练失败，因此必须先做最小 batch proof。

## Proof 4: manual confusion matrix

$$TP + FP + TN + FN = N_{test}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{FNR} = \frac{FN}{TP + FN}$$

### PI-MLP test set 当前结果

$TP = 12, FP = 0, TN = 8, FN = 0$ ; Recall = 1.00; FNR = 0.00; PF calls saved fraction = 0.40。

## Holdout results

| Model       | Recall | Precision | FNR  | Saved | Missed |
|-------------|--------|-----------|------|-------|--------|
| BaselineMLP | 1.00   | 0.857     | 0.00 | 0.30  | 0      |
| PI-MLP full | 1.00   | 1.000     | 0.00 | 0.40  | 0      |

### 说明

当前数据集很小，holdout 结果只用于教学验证；论文版必须扩展 scenario 数量和多随机种子。


## Loss ablation results

| Model          | Recall | Precision | Saved | AUPRC |
|----------------|--------|-----------|-------|-------|
| BaselineMLP    | 1.00   | 0.857     | 0.30  | 1.00  |
| PI-MLP no-rank | 1.00   | 0.923     | 0.35  | 1.00  |
| PI-MLP full    | 1.00   | 1.000     | 0.40  | 1.00  |

### 教学解读

本例中 full PI-MLP 在高召回下节省更多 PF 调用；小数据上不宜过度解读绝对数值。


# Training curves



## 观察

validation loss 用于 early stopping; 但最终安全指标仍然是 recall、FNR 和 missed violations。


# Precision–recall curves



## 为什么看 PR curve

安全筛查通常是类别不均衡问题，PR curve 比 accuracy 更关注 positive/unsafe 样本识别能力。


# Saved PF calls vs missed violations



## 工程解释

任何 saved PF calls 都要和 missed violations 同时报告；不能只说加速。

## True PI severity vs predicted severity




### 用途

检查 severity head 是否学到风险强弱，而不是只学二元标签。



# Component target distribution



## 解释性入口

component target distribution 能帮助学生理解数据集中主要风险来自哪类约束。

## Scenario-group 与 contingency-group CV

| CV type           | Folds | Mean recall | Mean FNR | Mean saved |
|-------------------|-------|-------------|----------|------------|
| Scenario-group    | 3     | 0.928       | 0.072    | 0.207      |
| Contingency-group | 3     | 0.760       | 0.240    | 0.413      |

### 关键结论

contingency-group CV 更难，说明仅靠 tabular metadata 泛化到未见过 contingency 仍有限；这是 Week 7 GNN 的动机。

Notebook 重新用相同随机种子训练 PI-MLP，并检查 test probabilities:

$$\max_i |\hat{p}_i^{(run1)} - \hat{p}_i^{(run2)}| < 10^{-6}$$

## 当前结果

最大差异为  $0.000 \times 10^0$  级别，fixed-seed reproducibility check 通过。

## Validation suite

当前 notebook 共检查 16 项:

- schema and binary labels;
- label/severity consistency;
- PI severity dominates component margins;
- no-leakage feature set;
- disjoint train/validation/test split;
- finite preprocessing, finite loss, finite gradients;
- manual confusion matrix;
- threshold selected from validation;
- scenario/contingency group CV disjoint;
- fixed-seed reproducibility。

### 结果

16/16 passed。

### 主要 CSV

- training curves;
- holdout results;
- loss ablation summary;
- group CV results;
- screening tradeoff;
- test predictions;
- validation summary。

### 主要 figures

- training curves;
- precision-recall curves;
- saved calls vs missed violations;
- true vs predicted severity;
- component target distribution。

- 当前样本数只有 77，用于教学足够，但论文版必须生成更大 scenario pool。
- PI-MLP 仍是 tabular model，没有显式编码 feeder topology。
- contingency-group CV 暴露出对未见 contingency 的泛化压力。
- $\lambda$  权重尚未系统搜索。
- 尚未做 uncertainty calibration / conformal screening。

### Week 6 PI-MLP

- tabular features;
- contingency metadata;
- PI loss design;
- high-recall screening。

### Week 7 Phase-aware GNN

- bus/phase nodes;
- line/device edges;
- contingency mask;
- topology-aware generalization。

### 核心动机

把拓扑从 feature engineering 中解放出来，交给图模型显式学习。

- ① 把 VUF 阈值从 2 percent 改成 1.5 percent, 观察 component margin 分布。
- ② 关闭 prob\_sev loss, 检查 probability 与 severity 是否仍然同向。
- ③ 关闭 ranking loss, 对比 top-k contingency ordering。
- ④ 把 target recall 从 0.95 改成 1.00, 观察 saved PF calls 如何变化。
- ⑤ 思考: 哪些内容应该保留到 Week 7 的 GNN loss 中?



- Notebook 使用 PyTorch 实现 multi-head MLP 和自定义 loss。
- 使用 scikit-learn 完成 preprocessing、AUPRC/AUROC 与 GroupKFold。
- 所有结果表和图表保存在 `week6_outputs_complete/`。
- clean notebook 适合课堂发放；executed notebook 适合教师检查和复现。