

Week 7: Phase-aware GNN 与高召回三相 N-1 筛查


Topology-aware graph learning for unbalanced microgrid security prediction

ECE Course: Physics-informed AI for Microgrid Security Prediction

本周学习目标

- ① 把三相微电网表示为 bus-level graph。
- ② 构造 phase-channel node features、edge features 和 global features。
- ③ 用 contingency mask 编码 line outage、PV trip、BESS trip 和 PCC outage。
- ④ 实现一个不依赖 PyTorch Geometric 的 message-passing GNN。
- ⑤ 证明 graph tensor、mask、split、loss 和 metric 代码正确。
- ⑥ 使用 high-recall threshold 和 top-k ranking 做 AI-assisted N-1 screening。

八周项目中的位置



Week 7 的角色

把 flattened features 升级为 topology-aware graph input, 并把 high-recall screening 扩展到 top-k contingency ranking。

Week 5/6 表格模型

$$\hat{y} = f_{\theta}(\mathbf{f}(x_t, c))$$

- 一行样本对应一组 features。
- 拓扑位置需要手工编码。
- line outage 下游影响不显式。

Week 7 图模型

$$\hat{y} = f_{\theta}(G_{t,c})$$

- bus 是节点，line 是边。
- A/B/C 三相信息是 node channels。
- outage mask 改变 message passing。

为什么 Microgrid 适合 GNN

- line outage 风险与 feeder 拓扑、下游负荷、上游供电路径强相关。
- PV/BESS trip 的风险不仅取决于容量，也取决于接入位置。
- VUF 风险依赖 A/B/C 三相负荷和 DER 的空间分布。
- PCC outage 是 system-level contingency，需要全局图状态。

核心动机


GNN 不是替代 pandapower，而是作为三相 N-1 全扫描前的快速候选排序器。

给定 operating scenario x_t 和 contingency c_k :

$$G_{t,k} = (\mathcal{N}, \mathcal{E}, X_t, E_k, g_{t,k})$$

- $X_t \in \mathbb{R}^{N \times F_x}$: bus-level phase-channel node features。
- $E_k \in \mathbb{R}^{2L \times F_e}$: directed edge features and outage mask。
- $g_{t,k} \in \mathbb{R}^{F_g}$: scenario、base-case security、contingency metadata。
- $y_{t,k} \in \{0, 1\}$: Week 4 violation label。

$$\hat{p}_{t,k} = \Pr(y_{t,k} = 1 \mid G_{t,k})$$



MVP 设计

9 个 buses, 8 条 undirected lines, 转换为 16 条 directed edges。该拓扑足够小, 便于学生逐项检查 tensor 和 mask。

节点仍然是 bus

不是把每个 bus 拆成 $(i, a), (i, b), (i, c)$ 三个相节点，而是把 A/B/C 信息放入同一个 bus 的特征向量。

示例 node features

```
is_pcc, is_critical, is_pv_bus, is_bess_bus;  
 $P_a^{load}, P_b^{load}, P_c^{load}; P_a^{PV}, P_b^{PV}, P_c^{PV};$   
 $P_a^{BESS,dis}, P_b^{BESS,dis}, P_c^{BESS,dis};$   
 $P_a^{BESS,ch}, P_b^{BESS,ch}, P_c^{BESS,ch};$  contingency flags and bus depth.
```

本周 MVP: bus-level

- 节点数量小。
- 实现简单。
- 适合一周课程。
- A/B/C 作为 channels。

论文扩展: phase-level

- 节点为 $(i, a), (i, b), (i, c)$ 。
- 更自然表示单相 DER。
- 需要建模相间耦合。
- 适合期刊扩展。

Contingency Encoding

Contingency	Graph encoding
line outage	edge availability $a_{ij} = a_{ji} = 0$, 并标记端点 bus
PV trip	标记 PV bus, 加入 PV trip global flag
BESS trip	标记 BESS bus, 加入 BESS trip global flag
PCC outage	标记 PCC bus, 加入 no-slack / PCC outage global flag

同一个 scenario, 多张 graph

同一 operating scenario 下, 不同 contingency 对应不同 E_k 和 $g_{t,k}$, 因此模型可以给不同故障排序。

$$h_i^{(0)} = \phi_x(x_i)$$

$$m_{ij}^{(r)} = a_{ij} \psi_{\theta} \left(h_j^{(r)}, e_{ij} \right)$$

$$h_i^{(r+1)} = \sigma \left(W_s h_i^{(r)} + \sum_{j \in \mathcal{N}(i)} m_{ij}^{(r)} \right)$$

- $a_{ij} = 1$: line available, message passes。
- $a_{ij} = 0$: line outage, message blocked。

Graph-level Readout

经过 K 层 message passing 后:

$$h_G = \text{mean}_{i \in \mathcal{N}} h_i^{(K)}$$

拼接 global features:

$$z = [h_G, g_{t,k}]$$

输出 unsafe probability:

$$\hat{p}_{t,k} = \sigma(w^\top z + b)$$

为什么用 mean pooling

mean pooling 简单、稳定、对节点排列不敏感，适合作为教学版 graph-level classifier。

为了公平比较，本周还训练一个非图模型：

$$\mathbf{z} = \text{flatten}(X, E, g), \quad \hat{p} = \text{MLP}(\mathbf{z})$$

- 输入信息量与 GNN 接近。
- 不显式使用 edge index 和 message passing。
- 用来判断 topology-aware inductive bias 是否带来收益。

注意

小数据集上 FlattenedMLP 可能表现更好；这不是失败，而是实验解释的一部分。

Week 7 读取 Week 4/5 输出:

- week5_outputs_complete/week5_ml_input_dataset.csv
- week4_outputs_complete/week4_contingency_table.csv

每一行仍是 $(x_t, c_k, y_{t,k}, s_{t,k})$, 但会转换为:

- X_{node} : $[n_{samples}, n_{bus}, n_{node \text{ features}}]$;
- E_{edge} : $[n_{samples}, n_{directed \text{ edges}}, n_{edge \text{ features}}]$;
- G_{global} : $[n_{samples}, n_{global \text{ features}}]$ 。

允许输入

- scenario settings;
- base-case voltage/VUF/loading;
- static topology;
- device placement;
- contingency identity/location。

禁止输入

- post-contingency voltage;
- post-contingency loading;
- post-contingency VUF;
- violation flags;
- severity score;
- convergence/service-loss label。

Graph Tensor Proof

Notebook 检查:

- graph connected;
- graph radial: $|\mathcal{E}| = |\mathcal{N}| - 1$;
- directed edge count: $2|\mathcal{E}|$;
- node / edge / global tensors finite;
- edge availability 和 outage flag 保持二元。

执行结果

$X : (77, 9, 26), \quad E : (77, 16, 6), \quad G : (77, 16)$

Contingency Mask Proof

- line outage: 恰好两个 directed edges 被置为 unavailable;
- non-line contingencies: PV/BESS/PCC 不改变 line availability;
- PV trip: 恰好标记一个 PV bus;
- BESS trip: 恰好标记 BESS bus;
- PCC outage: 恰好标记 PCC bus。

为什么重要

如果 mask 错了, GNN 学到的是错误拓扑; 即使指标好, 也没有工程可信度。

Permutation-invariance Proof

Graph-level prediction 不应依赖任意 bus 排列:

$$\hat{p}(G) = \hat{p}(\pi(G))$$

其中 π 同时重排 node tensor 并 remap edge index。

Notebook 检查

随机选择一个样本，随机重排 bus order，并用 remapped edge index 重新预测。

通过标准

$$|\hat{p}(G) - \hat{p}(\pi(G))| < 10^{-6}。$$

- ① Random holdout: train / validation / test。
 - ② Scaler 只在 training samples 上 fit。
 - ③ Validation set 选择 high-recall threshold。
 - ④ Test set 只报告最终结果。
 - ⑤ Group CV 检查 unseen scenario 和 unseen contingency。
- $$\max_{\tau} \text{PFCallsSaved}_{val}(\tau) \quad \text{s.t.} \quad \text{Recall}_{val}(\tau) \geq 0.95$$

High-recall Screening Metrics

Metric	Meaning
Recall	unsafe contingencies sent to detailed PF
FNR	missed unsafe fraction
Precision	fraction of screened-positive cases that are truly unsafe
PF calls saved	cases predicted safe and skipped
Missed violations	false negatives; most safety-critical number
AUPRC	useful under class imbalance
Top-k recall	dangerous contingencies covered by top- k ranking

安全筛查核心

准确率不是核心。漏报 unsafe contingency 才是最危险的错误。

Top-k Contingency Ranking

对每个 scenario:


- ① 计算所有 candidate contingencies 的 risk score;
- ② 按 score 从高到低排序;
- ③ 只对 top- k contingencies 运行三相 PF;
- ④ 统计 violation $\text{recall}@k$ 。

$$\text{Recall}@k = \frac{\#\{\text{unsafe contingencies in top-}k\}}{\#\{\text{unsafe contingencies}\}}$$


避免自评泄漏

Notebook 使用 scenario-group out-of-fold scores 做 top-k ranking。


训练曲线



Precision-Recall 曲线



Saved PF Calls vs Missed Violations




Random Holdout 结果

Model	Recall	Precision	FNR	Saved	Missed	AUPRC
FlattenedMLP	1.000	1.000	0.000	0.400	0	1.000
PhaseAwareGNN	0.583	0.875	0.417	0.600	5	0.913

如何解释

教学数据只有 77 个样本。这里 MLP 更强，说明当前 flattened features 已经很有信息量，而 GNN 需要更多 scenarios、更多拓扑或更强正则化才能稳定体现优势。




CV type	Folds	Mean recall	Mean precision	Mean FNR	Missed
Scenario-group	7	0.690	0.739	0.310	18
Contingency-group	11	0.896	0.665	0.104	8

结论

Unseen scenario 比 unseen contingency 更难，说明 operating condition diversity 是后续数据集扩展的重点。

Top-k Violation Recall



Top-k 结果解读

k	PF call fraction	Mean recall@ k	Severe hit@ k
1	0.091	0.156	1.000
3	0.273	0.468	1.000
5	0.455	0.636	1.000
7	0.636	0.948	1.000
8	0.727	0.961	1.000
11	1.000	1.000	1.000

操作含义

在该教学数据上，若每个 scenario 只扫描 top-7 contingencies，平均可覆盖约 95 percent unsafe contingencies，同时减少约 36 percent PF calls。

Validation Suite

Notebook 保存 44 项 validation checks:

- base graph connected;
- radial topology;
- directed edge count;
- finite tensors;
- line outage mask;
- PV/BESS/PCC flags;
- no post-contingency leakage;
- split disjoint;
- preprocessing finite;
- forward shape;
- finite loss / gradients;
- permutation invariance;
- group CV disjoint;
- top-k finite.

执行结果

44/44 checks passed.

- 1 Load Week 4/5 datasets。
- 2 Define teaching microgrid graph。
- 3 Construct node, edge, global features。
- 4 Run graph tensor and no-leakage proofs。
- 5 Split and scale train/val/test。
- 6 Define FlattenedMLP and PhaseAwareGNN。
- 7 Run permutation-invariance proof。
- 8 Train holdout models and select threshold。
- 9 Run scenario/contingency group CV。
- 10 Compute top-k ranking using OOF scores。
- 11 Save tables, figures, validation summary。

稳妥写法

We propose a phase-aware graph representation for three-phase microgrid N-1 security screening, where bus-level phase channels, line outage masks, and contingency-specific global features are combined in a message-passing classifier.

避免过度表述

不要写: GNN always outperforms MLP。

可以写: GNN provides a topology-aware prototype; superiority requires larger and more diverse feeders/scenarios.

后续可在 Week 8 或论文扩展中加入：

- 去掉 phase channels，只保留 total load/PV；
- 去掉 outage edge mask，只保留 contingency ID；
- mean pooling vs max pooling vs mean+max pooling；
- line outage only vs all contingency types；
- bus-level graph vs phase-level graph；
- 更多随机 operating scenarios。

- 当前数据集只有 7 scenarios 和 77 N-1 samples。
- 当前 feeder topology 单一，不能证明跨 feeder 泛化。
- Bus-level phase channels 还没有显式表示相间耦合。
- GNN 在小数据下可能不如 strong tabular baseline。
- 真正部署前仍需三相 PF 作为最终验证。

科研态度

安全应用中，AI screening 应该减少计算量，而不是跳过必要的工程验证。

Week 7 到 Week 8 的衔接

Week 8 将把 Weeks 4–7 组织成 mini-paper:

- Week 4: 三相 N-1 label generation;
- Week 5: traditional ML baseline;
- Week 6: physics-informed / limit-aware MLP;
- Week 7: phase-aware GNN and top-k screening;
- Week 8: paper figures、tables、method diagram、limitations。

最终论文主线

Fast but conservative AI-assisted screening for unbalanced microgrid N-1 static security assessment.

- ① 把 GNN 的 mean pooling 改为 max pooling。
- ② 去掉 cont_line_endpoint node flag, 只保留 edge outage mask。
- ③ 去掉 A/B/C phase channels, 只使用 total load/PV。
- ④ 把 hidden dimension 从 48 改为 16、32、96。
- ⑤ 用 scenario-group OOF scores 画每个 scenario 的 top-k ranking 表。
- ⑥ 设计 phase-level graph 的节点和边。

- 完整 clean notebook：课堂运行。
- executed notebook：教师检查与复现。
- 输出表：holdout results、group CV、top-k recall、validation summary。
- 输出图：training curves、PR curves、saved calls tradeoff、top-k recall。
- Week 8 可直接引用的 GNN method 和 limitation 表述。